


AI-textdetektor

Att skilja mänskligt och AI-genererat skrivande

Neuralt nätverk · TF-IDF · ~80% noggrannhet



Uppdraget

Vi fick i uppdrag att utveckla ett verktyg som kan avgöra om en text är skriven av en människa eller genererad av AI.

Uppdraget kom inte från det håll man kanske förväntar sig.

Uppdragsgivarna var inte ute efter att avslöja fuskare — de ville förstå skillnaderna för att göra sin AI-genererade kommunikation **varmare, mer personlig och lättare att ta till sig.**

Tänkbara uppdragsgivare

- Psykologmottagningar
- Primärvård & vårdcentraler
- Socialförvaltningar
- HR-avdelningar
- Utbildningsinstitutioner

Vår vinkel

Traditionell syn

Avslöja AI-text

Flagga automatgenererat innehåll, hitta fuskare i akademiska sammanhang och skydda mot desinformation.

Vår syn

Förstå skillnaderna — och minska dem

Verktuget fungerar som en spegel. Identifiera vad som skiljer mänskligt och maskinellt skrivande åt, och gör AI-text **varmare och mer personlig** — särskilt viktigt i vård och omsorg.

Metoden — tre feature-kanaler

Tre parallella feature-kanaler kombineras till en enda inmatning i nätverket.

1

Ord-TF-IDF

20 000 features

Fångar vilka ord och fraser som används. AI-text återkommer till formuleringar som "sammanfattningsvis" och "det bör noteras" som sällan dyker upp i naturligt skrivande.

2

Tecken-TF-IDF

8 000 features

Analyserar mönster på teckennivå — interpunktion, stavning, radbrytningar. char_wb n-gram (3-4 tecken) avslöjar stilistiska val som ordnivån missar.

3

Textstatistik

3 features

Ordantal, genomsnittlig meningslängd och lexikal mångfald. AI-text är ofta anmärkningsvärt jämn och välbalanserad — vilket paradoxalt avslöjar den.

Data & Förbehandling

332 000+

texter i datasetet

265 000

träningstexter

66 000


testtexter (30%)

Förbehandlingssteg


- Ta bort källnamn & URL:er (remove_source_leaks)
- Dela upp i träning / test FÖRE TF-IDF — undviker datainläckage
- Anpassa ord-TF-IDF och tecken-TF-IDF enbart på träningsdata
- Beräkna textstatistik (ordantal, meningslängd, lexikal mångfald)
- Kombinera kanalerna med hstack → StandardScaler

Utforskande dataanalys


Klassfördelning



Fördelning av textlängd (tecken)



Fördelning av ordantal



Grid Search — hyperparameteroptimering

scikeras + GridSearchCV, 3-fold korsvalidering, körs på urval för hanterbar körtid.

Sökta parametrar

Aktivering	relu, tanh
Dropout	0.2 / 0.3 / 0.4
Inlärningshastighet	0.001, 0.00003
Optimizer	adam
Neuroner lager 1	32
Neuroner lager 2	16

Bästa resultat

tanh

vann över relu som aktivering

Dropout 0.4 · lr 0.001 · adam

Balanced accuracy: 0.61

Tillämpades direkt i config.py — aktivering ändrades från relu till tanh.

Modell & Resultat

Arkitektur

Input

28 003 features

Dense 32 tanh + Dropout 0.4

+ L2-regularisering

Dense 16 tanh + Dropout 0.3

+ L2-regularisering

Dense 1 sigmoid

Binär klassificering

Resultat

~80%

noggrannhet på testdata

Precision (AI) 0.83


Recall (AI) 0.82

F1-score (snitt) 0.83


Early stopping **val_loss**

Träningshistorik

Förlust per epok




Noggrannhet per epok




Modellprestanda


ROC-kurva



Precision-Recall-kurva



Topp 5 viktigaste features (permutationsimportans)



Webbappen — Streamlit

streamlit run app.py → localhost:8501

1

Klistra in text

Valfri text matas in i ett textfält direkt i webbläsaren — ingen kod behövs.

2

Analys i realtid

Samma pipeline som träningen: källrensning → TF-IDF → statistik → skalning → förutsägelse.

3

Tydligt resultat

Visar AI / Människa / Oklart med konfidenspoäng och de ord som påverkade beslutet mest.

4

Export

Ladda ned en komplett analysrapport som CSV-fil direkt från webbläsaren.

Slutsats

Verktyget fungerar

~80% noggrannhet med tre komplementära feature-kanaler på ett stort och varierat dataset.

En ny vinkel

AI-textdetektering behöver inte bara handla om att avslöja — det kan vara ett verktyg för bättre mänsklig kommunikation.

Grid search gav svar

tanh visade sig bättre än relu — ett resultat som direkt tillämpades i config.py och förbättrade modellen.

Redo att använda

Webbappen gör det möjligt att testa modellen utan teknisk bakgrund.